IIC2413

AYUDANTÍA 12

Privacidad

PRIVACIDAD

Muchas bases de datos contienen información sensible o confidencial de personas.

Es nuestro deber hacer que estos datos sigan siendo privados.

¿CÓMO PRESERVAMOS LA PRIVACIDAD?

Técnicas de anonimización

Basadas en la generación de datos sintéticos

Permiten generar consultas sin pérdidas de datos importantes

Técnicas de privacidad diferencial

Es un mecanismo que garantiza que cuando un algoritmo aleatorio opera sobre un conjunto de datos, no revele información específica de ningún individuo

Asegura que la probabilidad de obtener un resultado particular es casi la misma, independientemente de si un individuo está o no en el conjunto de datos

DEFINICIONES Y CONVENCIONES

Identificador explícito (IdE)	Conjunto de atributos que individualmente identifican de manera explícita al “dueño” de un registro. Por ejemplo, nombre y RUT
Cuasi identificador (CId)	Conjunto de atributos que colectivamente tienen el potencial de identificar al dueño de un registro. Por ejemplo, día de nacimiento y dirección.
Atributos sensibles (AS)	Conjunto de atributos cuyo valor se desea proteger. Por ejemplo, religión, etnia, enfermedad, etc.
Atributos no-sensibles (AnS)	Conjunto de atributos que no tienen un carácter privado (y por lo tanto no se busca proteger). Por ejemplo, equipo de futbol o película favorita.

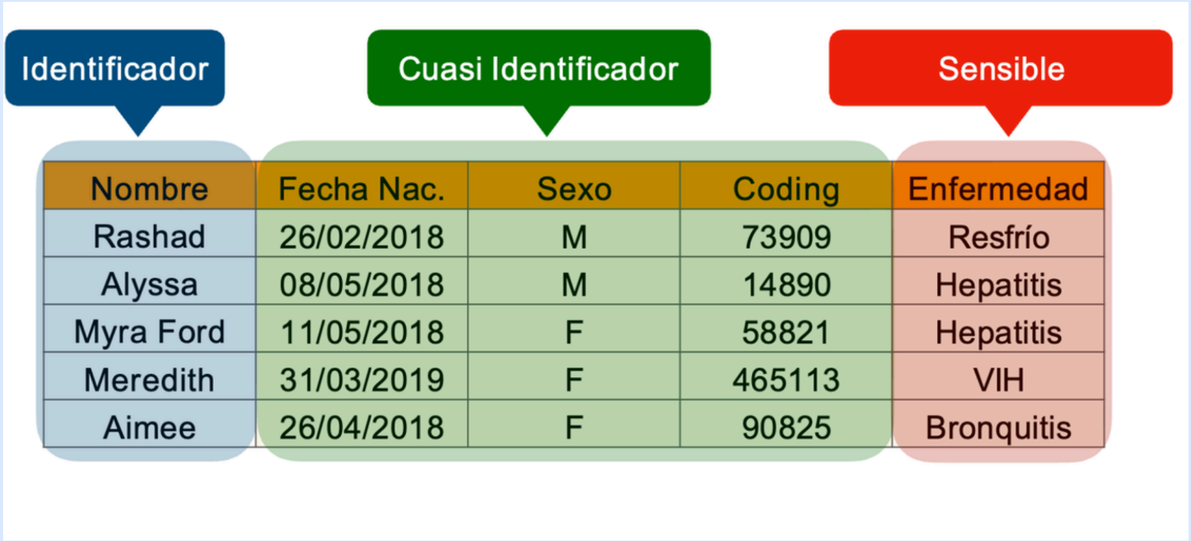


TABLA RESUMEN DE LAS TÉCNICAS

Técnica	Descripción / Objetivo	Mecanismo Principal	Vulnerabilidades o Limitaciones
De-identificación / Anonimización	Proceso general para remover la asociación entre una persona y un conjunto de datos, buscando maximizar la utilidad y reducir riesgos.	Técnicas como supresión (borrar datos), variación (revolver datos) y enmascaramiento (ocultar caracteres) .	Es vulnerable a ataques de re-identificación, especialmente el ataque de asociación de registros usando datos externos.
k-Anonimato	Garantía formal que asegura que ningún individuo sea únicamente identificable, "escondiéndolo" en un grupo de al menos k personas.	Generalización de datos para que cada grupo de cuasi-identificadores (ej. edad, código postal) aparezca al menos k veces en la tabla.	Susceptible a ataques de homogeneidad (si todos en el grupo tienen el mismo dato sensible) y ataques usando datos auxiliares.
L-Diversidad	Extensión del k-anonimato que busca asegurar variabilidad en los datos sensibles dentro de cada grupo anónimo.	Requiere que para cada grupo de cuasi-identificadores, existan al menos L valores distintos para los atributos sensibles.	Aunque mejora el k-anonimato, sigue siendo susceptible a ataques si el adversario posee cierta información auxiliar específica o negativa sobre el grupo.
Privacidad Diferencial	Mecanismo matemático que garantiza que el resultado de un análisis sea prácticamente el mismo, esté o no incluido un individuo específico en la base de datos .	Agrega ruido aleatorio (ej. Mecanismo de Laplace) a las respuestas de las consultas. Se controla mediante un "presupuesto de privacidad" (ϵ).	Dificulta la interpretación directa debido al ruido y no suele usarse para generar datos sintéticos (tablas completas), sino para respuestas a consultas específicas.

PRESERVAR PRIVACIDAD

Análisis que preserva privacidad

Un análisis preserva la privacidad si:
1. Se aprende algo útil.
2. No vulnera la privacidad de ningún individuo.

La privacidad de A se ve afectada si, al agregar sus datos, el analista aprende más que sin ellos (B + C en vez de solo B).

Privacidad vs. seguridad

Seguridad: quién puede manipular los datos (confidencialidad, integridad, disponibilidad).

Privacidad: qué se puede aprender a partir de los datos, es decir, de su contenido.

Idea clave: el resultado debe ser el mismo, sean o no considerados tus datos en el análisis.

CASOS Y SEUDONIMIZACIÓN

Casos que motivan

Netflix (2007): el dataset tenía IDs aleatorios, pero al cruzarlo con registros públicos de IMDb se re-identificó a los usuarios.

Gobernador de Massachusetts (1997): registros médicos «anonimizados» cruzados con el padrón electoral usando código postal, fecha de nacimiento y sexo.

Seudonimización vs. anonimización

Seudonimización: reversible con información adicional guardada aparte; los datos siguen siendo personales y la ley se aplica.

Anonimización (Ley 21.719): irreversible; el dato deja de ser personal.

Netflix estaba seudonimizado, no anonimizado. Hashear el RUT tampoco anonimiza (ataque de diccionario).

RE-IDENTIFICACIÓN

Ataque de asociación

Combina datos auxiliares con datos de-identificados (basta un JOIN) para volver a asociar a una persona con sus datos.

Los cuasi identificadores son la clave: sexo, código postal y fecha de nacimiento identifican de forma única al 87 % de las personas en EE. UU.

Ataque de diferenciación

Si se pueden hacer consultas propias, se restan dos resultados casi iguales.

SUM(age) de todos = 1256257
SUM(age) sin «Alan Brito» = 1256218
Diferencia = 39

¡Se descubre que Alan tiene 39 años!

K-ANONIMATO

Definición

Una tabla es k-anónima si cada combinación de valores de los cuasi identificadores (CId) aparece al menos k veces.

SELECT CIds, COUNT(*) FROM T GROUP BY CIds: cada conteo debe ser ≥ k.

Se logra generalizando (rangos de edad, código postal 130**) y eliminando valores atípicos (outliers).

Ataques a k-anonimato

Homogeneidad: si todo el grupo comparte el valor sensible (todos tienen cáncer), se aprende que Bob tiene cáncer.

Datos auxiliares: con conocimiento externo se descartan valores (los japoneses casi no tienen cardiopatías) y se infiere que Umeko tiene un resfrío.

L-DIVERSIDAD Y T-CLOSENESS

L-Diversidad

Además de k-anonimato: en cada grupo debe haber al menos l valores distintos del atributo sensible.

Previene la homogeneidad y resiste mejor los datos auxiliares.

Limitaciones: asimetría (si el 1 % tiene VIH y el grupo es 50/50, la sospecha sube de 1 % a 50 %) y similitud (gastritis, úlcera y cáncer gástrico: todas son enfermedades estomacales).

t-closeness

La distribución del atributo sensible en cada grupo debe estar a distancia ≤ t de su distribución en toda la tabla.

$D(P_{grupo}, P_{tabla}) = \frac{1}{2} \cdot \Sigma |p_i - q_i| \leq t$

Previene el ataque de asimetría y, con Earth Mover's Distance, mitiga el de similitud.

Costo: un t pequeño reduce la utilidad.

PRIVACIDAD DIFERENCIAL

Idea y definición

Mecanismo aleatorio cuyo resultado es casi el mismo, participe o no un individuo en los datos.

$Pr[f(x) \in S] \leq e^{\varepsilon} \cdot Pr[f(y) \in S]$, con x e y a distancia 1.

ε menor = más privacidad. La garantía no depende de los datos auxiliares del adversario.

Mecanismo de Laplace

$F(x) = f(x) + Lap(s / \varepsilon)$, con s = sensibilidad.

COUNT: s = 1. SUM con valores recortados a [0, U]: s = U.

ε es un presupuesto: en la composición secuencial los ε se suman; en la paralela (partes disjuntas) basta ε.

Solo sirve para consultas, no para datos sintéticos.

EJERCICIOS

PREGUNTA 3: EXAMEN 2025-1

Pregunta 3 - Privacidad (15 pts)

a) (4 pts.) ¿Cuáles de las siguientes condiciones se deben cumplir para que un análisis de dato preserve la privacidad? Justifique su respuesta.

I. El análisis tiene k-anonimato mayor o igual a 50.

II. El análisis tiene l-diversidad.

III. No se viola la privacidad de algún individuo.

IV. Se puede aprender algo del análisis.

V. Usa Privacidad Diferencial.

Solución

Solución: Al analizar cada una de las afirmaciones tenemos lo siguiente:

- I: Aunque el k-anonimato es una medida que aumenta la privacidad, no lo asegura.
- II: Aunque l-diversidad es una medida que aumenta la privacidad, tampoco lo asegura.
- III: Esta es una condición que debe cumplirse, ya que asegura que no se ha violado la privacidad de ningún individuo.
- IV: Al cumplir la privacidad, debe ser factible el aprendizaje a partir de los datos. De nada sirve tener privacidad, sin aprender de los datos.
- V: La privacidad diferencial es un mecanismo que incrementa la privacidad, pero no es requisito, ya que se pueden usar otros mecanismos.

Por lo tanto la respuesta correcta es III y IV.

PREGUNTA 3: EXAMEN 2025-1

(5 pts.) Relacione el concepto y su definición.

I. De-identificación (DeId)

II. Datos sintéticos (DS)

III. Re-identificación (ReId)

IV. k-Anonimato (kAn)

V. l-Diversidad (lDiv)

	Definición
1	Para cada grupo de filas con los mismos CIds, aparece al menos un cierto número de veces repetidos.
2	Para cada grupo de filas con los mismos CIds, por cada atributo sensible S, existen un cierto número de valores distintos.
3	Es el proceso que vuelve a asociar una persona con un conjunto de datos.
4	Es el proceso que remueve la asociación entre una persona y un conjunto de datos.
5	Son datos generados artificialmente, como forma opuesta a recolectarlos del mundo real.

SOLUCIÓN

	Definición	**Concepto**
1	Para cada grupo de filas con los mismos CIds, aparece al menos un cierto número de veces repetidos.	kAn
2	Para cada grupo de filas con los mismos CIds, por cada atributo sensible S, existen un cierto número de valores distintos.	lDiv
3	Es el proceso que vuelve a asociar una persona con un conjunto de datos.	ReId
4	Es el proceso que remueve la asociación entre una persona y un conjunto de datos.	DeId
5	Son datos generados artificialmente, como forma opuesta a recolectarlos del mundo real.	DS

PREGUNTA BONUS: I2 2026-1

a) Analiza las siguientes afirmaciones sobre privacidad en bases de datos y selecciona la alternativa correcta (2 pts)

I) La de-identificación garantiza que los datos anonimizados no pueden ser re-identificados.

II) Un ataque de diferenciación puede revelar información de un individuo ejecutando dos consultas de agregación cuidadosamente diseñadas.

III) El k-anonimato asegura que cada combinación de cuasi-identificadores aparece al menos k veces en la tabla.

A) Solo I y III son verdaderas

B) Solo II y III son verdaderas

C) Solo I es verdadera

D) Solo III es verdadera

E) Todas son verdaderas

PREGUNTA BONUS: I2 2026-1

I) La de-identificación garantiza que los datos anonimizados no pueden ser re-identificados **F**
Como muestra el caso del gobernador de Massachusetts, la de-identificación (enmascarar nombres) no garantiza protección; con datos auxiliares (cuasi-identificadores) se puede re-identificar a las personas mediante ataques de asociación.

II) Un ataque de diferenciación puede revelar información de un individuo ejecutando dos consultas de agregación cuidadosamente diseñadas **V**
Es el ejemplo visto en clases: `SUM(edad)` *sobre toda la tabla vs.* `SUM(edad)` *excluyendo a una persona específica permite despejar la edad de esa persona por diferencia.*

III) El k-anonimato asegura que cada combinación de cuasi-identificadores aparece al menos k veces en la tabla **V**
Es la definición formal exacta: T satisface k-anonimato si y solo si cada grupo de CIds aparece al menos k veces en T.

Respuesta correcta: B) Solo II y III son verdaderas

PREGUNTA BONUS: I2 2026-1

b) Considera la siguiente tabla anonimizada de pacientes. ¿Satisface esta tabla el 2-anonimato? Justifica usando la definición formal (2 pts)

Fecha Nac.	Sexo	Código Postal	Enfermedad
1990	M	750**	Diabetes
1990	M	750**	Hipertensión
1985	F	720**	Diabetes
1985	F	720**	Asma

PREGUNTA BONUS: I2 2026-1

Fecha Nac.	Sexo	Código Postal	Enfermedad
1990	M	750**	Diabetes
1990	M	750**	Hipertensión
1985	F	720**	Diabetes
1985	F	720**	Asma

Cuasi-identificadores: {Fecha Nac., Sexo, Código Postal}. Aplicando la definición formal:

- Grupo (1990, M, 750**): 2 registros
- Grupo (1985, F, 720**): 2 registros

Sí, satisface 2-anonimato. Cada combinación distinta de cuasi-identificadores aparece exactamente **2 veces** en la tabla ($\geq k = 2$), por lo que ningún individuo es distinguible de al menos otro 1 individuo dentro de su grupo de cuasi-identificadores.

PREGUNTA BONUS: I2 2026-1

c) Analiza las siguientes afirmaciones sobre la Ley 21.719 de Protección de Datos Personales en Chile y selecciona la correcta. (1 pto)

I) La ley aplica únicamente a empresas privadas, no a entidades públicas.

II) El titular de datos tiene derecho a solicitar la eliminación de sus datos cuando ya no sean necesarios.

III) Los datos sensibles incluyen información sobre salud, religión y orientación sexual.

A) Solo I es verdadera

B) Solo II y III son verdaderas

C) Solo I y III son verdaderas

D) Todas son verdaderas

E) Todas son falsas

PREGUNTA BONUS: I2 2026-1

I) La ley aplica únicamente a empresas privadas, no a entidades públicas **F**
La ley aplica tanto a personas naturales como jurídicas, incluyendo entidades públicas y privadas que operen en Chile.

II) El titular de datos tiene derecho a solicitar la eliminación de sus datos cuando ya no sean necesarios **V**
Es el "Derecho de supresión", uno de los 6 derechos fundamentales que otorga la ley.

III) Los datos sensibles incluyen información sobre salud, religión y orientación sexual **V**
Coincide exactamente con la definición de datos sensibles vista en clases.

Respuesta correcta: B) Solo II y III son verdaderas

¡MUCHAS GRACIAS!