

# Bases de Datos

## Clase 14: Privacidad

Ley 21.719 | Anonimización | k-Anonimato | ℓ-Diversidad | Privacidad diferencial

# Privacidad

## Motivación

Hasta ahora, el curso ha abordado los aspectos técnicos y teóricos de las bases de datos: álgebra relacional, programación en SQL y complejidad, entre otros.

Sin embargo, el diseño y el uso de una base de datos deben considerar también otras dimensiones, como la **privacidad**.



# Privacidad

## Riesgos del uso de datos personales

El uso de datos personales conlleva **riesgos**.

Los datos pueden contener **información sensible o confidencial** de los individuos.

**Médica**

**Financiera**

**Preferencias artísticas**

**Relaciones sociales**

**Riesgo para la privacidad**

Su uso puede **filtrar** (parte de) esta información sensible.

# Privacidad

## Definición y técnicas

Informalmente, se denomina **privacidad** a evitar que los datos de un individuo se hagan públicos o sean conocidos por terceros.

Dada la gran cantidad de datos existente en la actualidad, resulta necesario asegurar la privacidad de las bases de datos y de sus usos. Para ello existen distintas técnicas; en esta clase se estudiarán las siguientes:



# Privacidad

## Análisis que preserva privacidad

Un análisis de datos **preserva la privacidad** si:

1. Se aprende algo útil del análisis.
2. El análisis no vulnera la privacidad de ningún individuo.

La privacidad de un individuo A se ve **afectada** si:

**Sin los datos de A**

el analista aprende **B**.

**Al agregar los datos de A**

el analista aprende **B + C**.

**Un análisis preserva la privacidad de un individuo si el resultado es el mismo, sean o no considerados sus datos en el análisis.**

# Privacidad vs. seguridad

## Dos conceptos distintos

### Seguridad

Se refiere a **quién** puede manipular los datos:

- **Confidencialidad:** quién puede ver los datos.
- **Integridad:** quién puede modificar los datos.
- **Disponibilidad:** quién puede acceder a los datos cuando se requieren.
- Propuesta adicional: **resiliencia**.

### Privacidad

Se refiere a **qué** se puede aprender a partir de los datos, es decir, a su **contenido**.

# El caso de Netflix

## Competencia Netflix (2007)

En 2007, Netflix convocó a una competencia abierta para mejorar su sistema de recomendación.

**Premio**

**US$ 1.000.000**

**Participantes**

Acceso a un dataset de entrenamiento **anonimizado**

*«Para proteger la privacidad del cliente, se ha eliminado toda la información personal que identifica a clientes individuales y todos los ID de clientes han sido reemplazados por ID asignados aleatoriamente.»*

**¿Es suficiente esta medida? No.**

# El caso de Netflix

## Ataque de asociación de registros

El dataset entregado estaba anonimizado; sin embargo, **IMDb** disponía de registros públicos **no anonimizados** de las mismas personas.

**Dataset de Netflix anonimizado**

| Usuario | P1 | P2 | P3 |
|---|---|---|---|
| ??? | ★ | | ★ |
| ??? | | ★ | |
| ??? | ★ | ★ | |
| ??? | | | ★ |

+

**Registros públicos de IMDb**

| Usuario | P1 | P2 | P3 |
|---|---|---|---|
| Alice | ★ | | ★ |
| Bob | | ★ | |
| Caty | ★ | ★ | |
| Tim | | | ★ |

=

**Dataset de Netflix re-identificado**

| Usuario | P1 | P2 | P3 |
|---|---|---|---|
| Alice | ★ | | ★ |
| Bob | | ★ | |
| Caty | ★ | ★ | |
| Tim | | | ★ |

**Ataque de asociación de registros**

P1–P3: películas calificadas (★) por cada usuario.

# El caso del gobernador de Massachusetts

## Asociación con el padrón electoral

En 1997, William Weld, gobernador de Massachusetts, aprobó la publicación de los registros médicos de los funcionarios públicos, previa anonimización.






**William Weld**



**Latanya Sweeney**

Dos días después, Latanya Sweeney, entonces estudiante de doctorado del MIT, le envió por correo electrónico sus propios registros médicos.



Parte 1

# Ley 21.719 de Protección de Datos Personales en Chile

# ¿Qué es la Ley 21.719?

## Contexto

### Nueva legislación

Publicada en diciembre de 2024; entra en vigencia en (~~diciembre de 2026~~) octubre 2027 .

### Modernización legal

Modifica la antigua Ley 19.628 de 1999 y la adapta a los desafíos digitales actuales.

### Protección integral

Establece normas claras sobre el tratamiento y la protección de los datos personales de las personas naturales.

# Conceptos clave de la ley

## Terminología

Estos términos son fundamentales para comprender los derechos y responsabilidades que establece la ley.

### Datos personales

Toda información que identifica o permite identificar a una persona: nombre, RUT, correo, dirección, teléfono, fotografía o huella digital, entre otros.

### Datos sensibles

Información especialmente protegida: salud, creencias religiosas, orientación sexual, origen racial o étnico, opiniones políticas y vida íntima.

### Tratamiento de datos

Toda operación sobre los datos: recolección, almacenamiento, modificación, transmisión, consulta, eliminación u otra.

### Titular de datos

La persona natural a quien pertenecen los datos personales y que, según esta ley, tiene derechos sobre ellos.

# Derechos de los titulares de datos

## Derechos 01 a 03 de 06

La ley otorga **seis derechos fundamentales** para que el titular controle su información personal.

**01**

### Derecho de acceso

Conocer si los datos están siendo tratados, quién los posee y con qué finalidad se utilizan.

**02**

### Derecho de rectificación

Solicitar la corrección de datos incorrectos, inexactos o incompletos.

**03**

### Derecho de supresión

Solicitar la eliminación de los datos cuando ya no sean necesarios o su tratamiento sea ilícito.

# Derechos de los titulares de datos

## Derechos 04 a 06 de 06

### 04

### Derecho de oposición

Oponerse a que los datos sean tratados para determinados propósitos específicos.

### 05

### Derecho a la portabilidad

Obtener los datos en un formato electrónico estructurado, para transferirlos a otro responsable.

### 06

### Derecho de bloqueo

Suspender temporalmente el tratamiento de los datos mientras se verifica su exactitud o licitud.

# Principios que rigen el tratamiento

## Principios rectores de la ley

**Licitud y transparencia:** el tratamiento debe tener una base legal válida y comunicarse al titular de forma clara y comprensible.

**Finalidad específica:** los datos solo pueden usarse para los propósitos informados al momento de su recolección.

**Proporcionalidad:** solo se recolectan los datos estrictamente necesarios y pertinentes para el objetivo planteado.

**Calidad de los datos:** la información debe ser exacta, completa y mantenerse actualizada durante todo el tratamiento.

**Seguridad integral:** deben implementarse medidas técnicas y organizativas que protejan los datos contra accesos no autorizados, pérdida o destrucción.

# La Agencia de Protección de Datos

## Institucionalidad

### Organismo autónomo

Institución independiente creada por esta ley para velar por el cumplimiento de la normativa de protección de datos en Chile.

### Poder fiscalizador

Facultada para investigar, supervisar y aplicar sanciones significativas a empresas o instituciones que incumplan la ley.

### Promoción y educación

Promueve una cultura de respeto y protección de los datos personales mediante capacitaciones, guías y campañas educativas.

**Importante:** la Agencia es la principal instancia a la que puede recurrir el titular si considera vulnerados sus derechos: ante ella puede presentar denuncias y solicitar orientación sobre la protección de sus datos.

# Ámbito de aplicación de la ley

## ¿A quiénes y a qué situaciones aplica?

### Aplicación universal

Aplica a personas naturales y jurídicas, incluidas las entidades públicas y privadas que operan en Chile.

### Alcance territorial

Abarca todo tratamiento de datos realizado en territorio chileno o dirigido a personas que se encuentran en Chile.

### Excepciones limitadas

Excluye, bajo condiciones específicas, el tratamiento con fines periodísticos, artísticos, literarios o de investigación histórica.

# Ejemplos prácticos de la ley

## Situaciones cotidianas

### 1

### Comercio electrónico

En una compra en línea, la tienda debe solicitar consentimiento explícito antes de usar el correo o el teléfono del cliente con fines de marketing; no puede presumirse la aceptación de publicidad.

### 2

### Sector salud

Un hospital o clínica que almacena datos médicos debe protegerlos con la máxima seguridad y usarlos solo para la atención del paciente, sin compartirlos sin su autorización.

### 3

### Redes sociales

El titular puede solicitar a una red social la eliminación de información personal que ya no desea compartir, como fotografías antiguas o datos de perfil publicados hace tiempo.



Parte 2

# Técnicas de privacidad

# Datos sintéticos y respuesta a consultas

## Dos funcionalidades

### Datos sintéticos

Datos **generados artificialmente**, en oposición a los datos recolectados del mundo real.

### Respuesta a consultas

Respuestas que entregan datos **agregados** de alguna forma.

# Técnicas de privacidad

## Clasificación según funcionalidad

Cada técnica estudiada en esta clase se asocia a una funcionalidad:

| Técnica | Funcionalidad |
|---|---|
| Anonimización | Datos sintéticos |
| k-Anonimato | Datos sintéticos |
| ℓ-Diversidad | Datos sintéticos |
| t-Closeness | Datos sintéticos |
| Privacidad diferencial | Respuesta a consultas |

# Datos sintéticos vs. respuesta a consultas

## Datos sintéticos

Los datos sintéticos **lucen como** los datos originales:

### Datos originales

| Nombre | Fecha nac. | Sexo | Cód. postal |
|---|---|---|---|
| Rashad Arnold | 26/02/2018 | M | 73909 |
| Alyssa Cherry | 08/05/2018 | M | 14890 |
| Myra Ford | 11/05/2018 | F | 58821 |
| Meredith Perry | 31/03/2019 | F | 465113 |
| Aimee Thornton | 26/04/2018 | F | 90825 |

### Datos sintéticos

| Nombre | Fecha nac. | Sexo | Cód. postal |
|---|---|---|---|
| ****** | 26/02/2018 | M | 73909 |
| ****** | 08/05/2018 | M | 14890 |
| ****** | 11/05/2018 | F | 58821 |
| ****** | 31/03/2019 | F | 465113 |
| ****** | 26/04/2018 | F | 90825 |

**Mismo esquema y formato: pueden analizarse con las mismas herramientas**

# Datos sintéticos vs. respuesta a consultas

## Respuesta a consultas

Las respuestas a consultas **requieren** una consulta en particular:

| Nombre | Fecha nac. | Sexo | Cód. postal |
|---|---|---|---|
| Rashad Arnold | 26/02/2018 | M | 73909 |
| Alyssa Cherry | 08/05/2018 | M | 14890 |
| Myra Ford | 11/05/2018 | F | 58821 |
| Meredith Perry | 31/03/2019 | F | 465113 |
| Aimee Thornton | 26/04/2018 | F | 90825 |

**¿Cuántas personas nacieron en 2018?**

**4**

**¿Cuántas personas hay de cada sexo?**

**M = 2 y F = 3**

# Datos sintéticos vs. respuesta a consultas

## Comparación

### Datos sintéticos

1. Permiten reutilizar análisis de datos existentes.
2. Funcionan para todas las consultas.
3. Facilitan el trabajo de los analistas.
4. **Es imposible** obtener utilidad perfecta y privacidad fuerte.

### Respuesta a consultas

1. A veces requieren modificar los análisis de datos.
2. Dependen de cada consulta.
3. Dificultan el trabajo de los analistas.
4. La especialización a una consulta permite obtener **mejor utilidad y privacidad**.

# Utilidad

## ¿Qué tan útil es la respuesta?

La utilidad de una respuesta **depende del uso** que se le dará.

**Ejemplo: ¿cuántas personas se apellidan Ford?**

**Datos anonimizados** → **Imposible de responder**

**Privacidad diferencial** → **Se puede responder con un margen de ± 1 persona**



Parte 3

# Anonimización / de-identificación

# Definiciones y convenciones básicas

## Clasificación de atributos

Los atributos de una tabla se clasifican en **cuatro categorías disjuntas**:

### Identificador explícito (IdE)

Atributos que, individualmente, identifican de manera explícita al titular de un registro. Ej.: nombre y RUT.

### Cuasi identificador (CId)

Atributos que, en conjunto, pueden identificar al titular de un registro. Ej.: fecha de nacimiento y dirección.

### Atributo sensible (AS)

Atributos cuyo valor se desea proteger. Ej.: religión, etnia o enfermedad.

### Atributo no sensible (AnS)

Atributos sin carácter privado, que no se busca proteger. Ej.: equipo de fútbol o película favorita.

# Definiciones y convenciones básicas

## Ejemplo de clasificación

En la siguiente tabla, cada columna pertenece a una de las categorías:

| Identificador | Cuasi identificador | | | Sensible |
|---|---|---|---|---|
| **Nombre** | **Fecha nac.** | **Sexo** | **Cód. postal** | **Enfermedad** |
| Rashad | 26/02/2018 | M | 73909 | Resfrío |
| Alyssa | 08/05/2018 | M | 14890 | Hepatitis |
| Myra Ford | 11/05/2018 | F | 58821 | Hepatitis |
| Meredith | 31/03/2019 | F | 465113 | VIH |
| Aimee | 26/04/2018 | F | 90825 | Bronquitis |

Ninguna columna de este ejemplo corresponde a un atributo no sensible (AnS).

# De-identificación

## Definición, objetivos y técnicas

La **de-identificación** es el proceso que elimina la asociación entre una persona y un conjunto de datos.

### Objetivos

- Reducir el riesgo de violación de la privacidad.
- Maximizar la utilidad de los datos.

### Técnicas

- **Supresión:** remover datos.
- **Variación:** «revolver» los datos.
- **Enmascaramiento.**

# De-identificación: ejemplo

## Enmascaramiento

| Nombre | Fecha nac. | Sexo | Cód. postal |
|---|---|---|---|
| Rashad Arnold | 26/02/2018 | M | 73909 |
| Alyssa Cherry | 08/05/2018 | M | 14890 |
| Myra Ford | 11/05/2018 | F | 58821 |
| Meredith Perry | 31/03/2019 | F | 465113 |
| Aimee Thornton | 26/04/2018 | F | 90825 |



| Nombre | Fecha nac. | Sexo | Cód. postal |
|---|---|---|---|
| ****** | 26/02/2018 | M | 73909 |
| ****** | 08/05/2018 | M | 14890 |
| ****** | 11/05/2018 | F | 58821 |
| ****** | 31/03/2019 | F | 465113 |
| ****** | 26/04/2018 | F | 90825 |

**En estos datos, los nombres han sido enmascarados**

# Seudonimización vs. anonimización

## Definiciones de la Ley 21.719 (art. 2, letras k y l)

### Seudonimización

Los datos ya no pueden atribuirse a un titular **sin usar información adicional**, que se guarda por separado y protegida.

**Es reversible para quien posee esa información: los datos siguen siendo personales y la ley se aplica.**

### Anonimización

Procedimiento **irreversible**: se destruye o elimina el nexo con la información que identifica a la persona.

**El dato anonimizado deja de ser un dato personal.**

**El dataset de Netflix (ID reemplazados por ID aleatorios) estaba seudonimizado, no anonimizado**

# Seudonimización en el esquema

## Tabla de correspondencia separada

### Atencion (datos de uso general)

| seudonimo | fecha_nac | zip | diagnostico |
|---|---|---|---|
| a7f3 | 26/02/2018 | 73909 | Resfrío |
| c91e | 08/05/2018 | 14890 | Hepatitis |
| e204 | 11/05/2018 | 58821 | Hepatitis |

### Correspondencia (restringida)

| seudonimo | rut | nombre |
|---|---|---|
| a7f3 | 11.458.233-6 | Rashad Arnold |
| c91e | 15.302.871-0 | Alyssa Cherry |
| e204 | 9.874.120-8 | Myra Ford |

```
SELECT c.nombre, a.diagnostico
FROM Atencion a
JOIN Correspondencia c
  ON a.seudonimo = c.seudonimo;
```

**Quien puede ejecutar este JOIN puede re-identificar: los datos siguen siendo personales**

**Además, fecha_nac y zip son CId: aun sin la tabla de correspondencia, un ataque de asociación sigue siendo posible**

# Hashear el RUT no lo anonimiza

## Ataque de diccionario

Se publica una tabla en la que el RUT se reemplazó por su hash SHA-256. Pero los RUT de personas naturales son números del orden de **30 millones**: basta calcular el hash de todos y hacer un JOIN.

```
-- dv(n): dígito verificador de n
SELECT d.rut, p.diagnostico
FROM Publicada p
JOIN (SELECT n || '-' || dv(n) AS rut
      FROM generate_series(1, 30000000) n) d
  ON p.rut_hash = sha256(d.rut::bytea);
```

**$\approx 3 \times 10^7$**

hashes: segundos con código optimizado; minutos incluso desde SQL

**Agregar una «sal» conocida no ayuda: el atacante la incluye en el diccionario**

**Un hash con clave secreta (HMAC) es seudonimización: quien tiene la clave puede revertirlo**

# Re-identificación

## Ataque de asociación de registros

La **re-identificación** es el proceso que vuelve a asociar una persona con un conjunto de datos.

| Nombre | Fecha nac. | Sexo | Cód. postal | Enfermedad |
|---|---|---|---|---|
| ***** | 26/02/2018 | M | 73909 | Resfrío |
| ***** | 08/05/2018 | M | 14890 | Hepatitis |
| ***** | 11/05/2018 | F | 58821 | Hepatitis |
| ***** | 31/03/2019 | F | 465113 | VIH |
| ***** | 26/04/2018 | F | 90825 | Bronquitis |

+

| Nombre | Fecha nac. |
|---|---|
| Rashad Arnold | 08/05/2018 |

**Depende de datos auxiliares**

| Nombre | Fecha nac. | Sexo | Cód. postal | Enfermedad |
|---|---|---|---|---|
| Rashad Arnold | 08/05/2018 | M | 14890 | Hepatitis |

**También llamado ataque de asociación de registros**

**¡Se logró re-identificar a Rashad!**

# Re-identificación

## Ataque de diferenciación

El problema se agrava cuando es posible **diseñar consultas propias**.

1. Una consulta de suma sobre un grupo grande puede parecer adecuada:

```
SELECT SUM(age) FROM person;
```

**1256257**

2. Pero es posible realizar otra consulta sobre un grupo grande:

```
SELECT SUM(age) FROM person
WHERE nombre <> 'Alan Brito';
```

**1256218**

```
1256257 - 1256218 = 39
```

**¡Se descubre que Alan tiene 39 años!**

# Resumen

## Ataques de asociación

Un ataque de asociación combina **datos auxiliares** con datos de-identificados para re-identificar a las personas. En el caso más simple, basta un **join** entre las dos tablas que contienen estos conjuntos de datos.

Los ataques de asociación simples son sorprendentemente efectivos:

### 1 CId

basta para reducir la búsqueda a unos pocos registros.

### 2 CId

suelen bastar para re-identificar a una gran fracción de la población de un conjunto de datos.

### 3 CId

(sexo, código postal y fecha de nacimiento) identifican de forma única al 87 % de las personas en EE. UU.



## Parte 4

# *k*-Anonimato

# ¿Qué es *k*-anonimato?

## Definición [Samarati y Sweeney, 1998]

Sea $T(A_1, \ldots, A_n)$ una tabla y $Q$ el conjunto de CId asociados a ella.

Se dice que $T$ satisface ***k*-anonimato** si y solo si cada combinación de valores de $Q$ aparece al menos $k$ veces en $T$.

```
SELECT CIds, COUNT(*) FROM T GROUP BY CIds
```

**Cada conteo debe ser ≥ *k***

**Garantía formal: ningún individuo es identificable de forma única dentro de un grupo de tamaño k**

**Limitación: aún requiere identificar a todos los cuasi identificadores**

# *k*-Anonimato: ejemplo

## Tabla person (Adult Census)

| name | ssn | age | education_num | … | target |
|---|---|---|---|---|---|
| Karrie Trusslove | 732-14-61 | 39 | 13 | … | <=50K |
| Brandise Tripony | 150-19-27 | 50 | 13 | … | <=50K |
| Brenn McNeely | 725-59-98 | 38 | 9 | … | <=50K |
| Dorry Poter | 659-57-49 | 53 | 7 | … | <=50K |
| Dick Honnan | 220-93-38 | 28 | 13 | … | <=50K |
| … | … | … | … | … | … |
| Ardyce Golby | 212-61-83 | 27 | 12 | … | <=50K |
| Jean O'Connor | 737-32-29 | 40 | 9 | … | >50K |
| Reuben Skrzynski | 314-48-02 | 58 | 9 | … | <=50K |
| Caye Biddle | 647-75-35 | 22 | 9 | … | <=50K |
| Hortense Hardesty | 690-42-56 | 52 | 9 | … | >50K |

```
SELECT age AS a, education_num AS e,
       COUNT(*) AS c
FROM person
GROUP BY age, education_num
ORDER BY c ASC;
```

| a | e | c |
|---|---|---|
| 81 | 15 | 1 |
| 73 | 14 | 1 |
| 30 | 1 | 1 |
| 68 | 2 | 1 |
| 71 | 1 | 1 |
| … | … | … |
| 33 | 9 | 313 |
| 35 | 9 | 320 |
| 19 | 10 | 329 |
| 21 | 10 | 372 |
| 20 | 10 | 413 |

**Tabla 1-anónima**

Filas resaltadas: grupos con un solo individuo.

# *k*-Anonimato: generalización

## Agrupar valores en rangos de 10

```
SELECT (age/10)*10 AS a,
       (education_num/10)*10 AS e,
       COUNT(*) AS c
FROM person
GROUP BY (age/10)*10,
         (education_num/10)*10
ORDER BY c ASC;
```

| a | e | c |
|---|---|---|
| 90 | 0 | 1 |
| 80 | 0 | 2 |
| 70 | 0 | 7 |
| 70 | 10 | 9 |
| 10 | 10 | 12 |
| 60 | 10 | 13 |
| … | … | … |
| 30 | 0 | 122 |
| 30 | 10 | 148 |
| 20 | 10 | 157 |
| 40 | 10 | 160 |

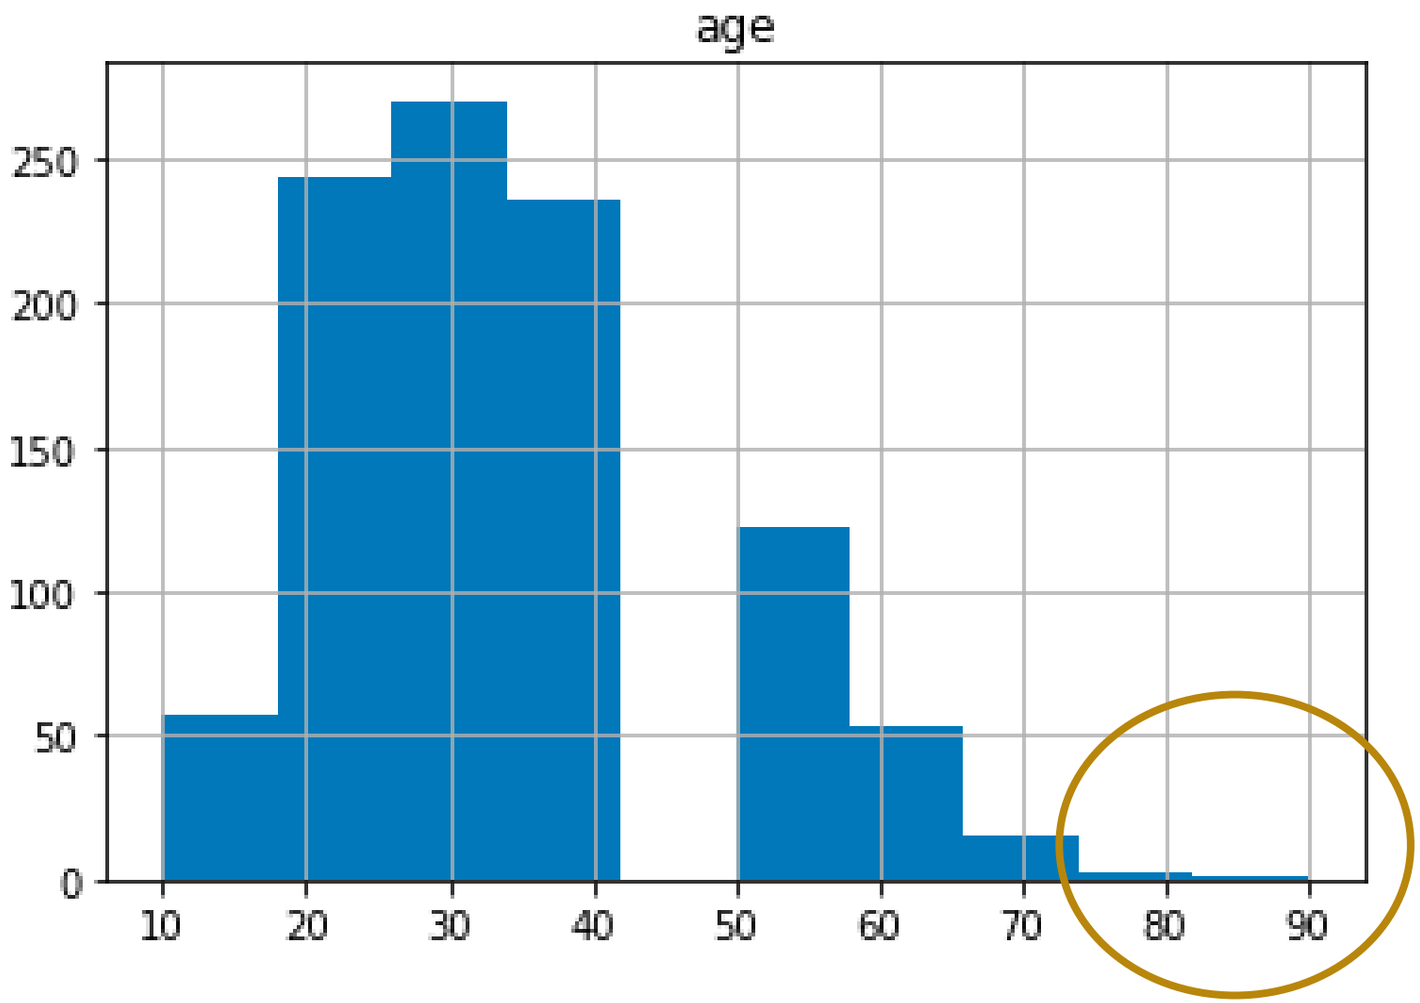
**Sigue siendo 1-anónima**

**Mejora, pero ahora aparecen valores atípicos (outliers)**

# *k*-Anonimato: valores atípicos

## Distribución de la edad

| a | e | c |
|---|---|---|
| 90 | 0 | 1 |
| 80 | 0 | 2 |
| 70 | 0 | 7 |
| 70 | 10 | 9 |
| 10 | 10 | 12 |
| 60 | 10 | 13 |
| … | … | … |
| 30 | 0 | 122 |
| 30 | 10 | 148 |
| 20 | 10 | 157 |
| 40 | 10 | 160 |




**El problema son los valores atípicos (outliers)**

**Idea: eliminar los outliers**

# *k*-Anonimato: eliminando outliers

## Truncar las edades mayores que 60

Se truncan a 60 los valores de *a* mayores que 60:

```
SELECT LEAST((age/10)*10, 60) AS a,
       (education_num/10)*10 AS e,
       COUNT(*) AS c
FROM person
GROUP BY LEAST((age/10)*10, 60),
         (education_num/10)*10
ORDER BY c ASC;
```

**Se logra 12-anonimato**

| a | e | c |
|---|---|---|
| 10 | 10 | 12 |
| 60 | 10 | 22 |
| 10 | 0 | 45 |
| 60 | 0 | 50 |
| 50 | 10 | 53 |
| 50 | 0 | 69 |
| 40 | 0 | 76 |
| 20 | 0 | 86 |
| 30 | 0 | 122 |
| 30 | 10 | 148 |
| 20 | 10 | 157 |
| 40 | 10 | 160 |

# *k*-Anonimato: agregando más datos

## Mismo procedimiento, mayor volumen

| a | e | c |
|---|---|---|
| 10 | 10 | 455 |
| 60 | 10 | 1172 |
| 10 | 0 | 1202 |
| 60 | 0 | 1472 |
| 50 | 0 | 2172 |
| 50 | 10 | 2246 |
| 40 | 0 | 2795 |
| 20 | 0 | 3380 |
| 30 | 0 | 3733 |
| 40 | 10 | 4380 |
| 20 | 10 | 4674 |
| 30 | 10 | 4880 |

Al aplicar la misma consulta sobre un conjunto de datos de **mayor tamaño**:

```
SELECT LEAST((age/10)*10, 60) AS a,
       (education_num/10)*10 AS e,
       COUNT(*) AS c
FROM person
GROUP BY LEAST((age/10)*10, 60),
         (education_num/10)*10
ORDER BY c ASC;
```

**Se logra 455-anonimato**

# *k*-Anonimato: otro ejemplo

## Generalización de cuasi identificadores

| zip | edad | nacionalidad | enfermedad |
|---|---|---|---|
| 13053 | 28 | Rusa | Cardiopatía |
| 13068 | 29 | Estadounid. | Cardiopatía |
| 13068 | 21 | Japonesa | Resfrío |
| 13053 | 23 | Estadounid. | Resfrío |
| 14853 | 50 | India | Cáncer |
| 14853 | 55 | Rusa | Cardiopatía |
| 14850 | 47 | Estadounid. | Resfrío |
| 14850 | 59 | Estadounid. | Resfrío |
| 13053 | 31 | Estadounid. | Cáncer |
| 13053 | 37 | India | Cáncer |
| 13068 | 36 | Japonesa | Cáncer |
| 13068 | 32 | Estadounid. | Cáncer |

**1-anónima**

| zip | edad | nacionalidad | enfermedad |
|---|---|---|---|
| 130** | <30 | * | Cardiopatía |
| 130** | <30 | * | Cardiopatía |
| 130** | <30 | * | Resfrío |
| 130** | <30 | * | Resfrío |
| 1485* | >40 | * | Cáncer |
| 1485* | >40 | * | Cardiopatía |
| 1485* | >40 | * | Resfrío |
| 1485* | >40 | * | Resfrío |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |

**4-anónima**

¿Existe algún problema? **Sí**: con ciertos datos es posible realizar ataques por:

- **Homogeneidad**
- **Datos auxiliares**

# Ataque #1: homogeneidad

## Ataque a *k*-anonimato

Si se sabe que Bob tiene **35 años** y que su código postal está en el rango 130** …

| nombre | zip | edad | nac. |
|---|---|---|---|
| Bob | 13053 | 35 | ?? |

| zip | edad | nacionalidad | enfermedad |
|---|---|---|---|
| 130** | <30 | * | Cardiopatía |
| 130** | <30 | * | Cardiopatía |
| 130** | <30 | * | Resfrío |
| 130** | <30 | * | Resfrío |
| 1485* | >40 | * | Cáncer |
| 1485* | >40 | * | Cardiopatía |
| 1485* | >40 | * | Resfrío |
| 1485* | >40 | * | Resfrío |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |

**El grupo 30-40 es homogéneo: todos tienen cáncer**

**Se aprende que Bob tiene cáncer**

# Ataque #2: datos auxiliares

## Ataque a *k*-anonimato

| zip | edad | nacionalidad | enfermedad |
|---|---|---|---|
| 130** | <30 | * | Cardiopatía |
| 130** | <30 | * | Cardiopatía |
| 130** | <30 | * | Resfrío |
| 130** | <30 | * | Resfrío |
| 1485* | >40 | * | Cáncer |
| 1485* | >40 | * | Cardiopatía |
| 1485* | >40 | * | Resfrío |
| 1485* | >40 | * | Resfrío |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |

Si se sabe que las personas japonesas tienen una **incidencia muy baja** de enfermedades cardíacas…

| nombre | zip | edad | nac. |
|---|---|---|---|
| Umeko | 13068 | 24 | Japonesa |

**Umeko pertenece al grupo <30: cardiopatía o resfrío**

**Se aprende que Umeko tiene un resfrío**



Parte 5

# ℓ-Diversidad y *t*-closeness

# ¿Qué es ℓ-diversidad?

## Definición [Machanavajjhala et al., 2006]

Además de lo exigido por *k*-anonimato:

Una tabla *T* es **ℓ-diversa** si, para cada grupo de filas con los mismos CId y para cada atributo sensible *S*, existen al menos ℓ valores distintos.

```
SELECT CIds, COUNT(DISTINCT S) FROM T GROUP BY CIds
```

**Cada conteo debe ser ≥ ℓ**

**Previene el ataque #1 (homogeneidad)**

**Aumenta la resistencia frente al ataque #2 (datos auxiliares)**

# Ataque a ℓ-diversidad: datos auxiliares

## Primera inferencia

Si se sabe que las personas japonesas tienen una **incidencia muy baja** de enfermedades cardíacas…

| nombre | zip | edad | nac. |
|---|---|---|---|
| Umeko | 13068 | 24 | Japonesa |

- Umeko no tiene cáncer.
- Umeko no tiene una enfermedad cardíaca.

**Umeko podría tener diabetes o un resfrío**

| zip | edad | nacionalidad | enfermedad |
|---|---|---|---|
| 130** | <30 | * | Cardiopatía |
| 130** | <30 | * | Diabetes |
| 130** | <30 | * | Cáncer |
| 130** | <30 | * | Resfrío |
| 1485* | >40 | * | Cáncer |
| 1485* | >40 | * | Cardiopatía |
| 1485* | >40 | * | Resfrío |
| 1485* | >40 | * | Resfrío |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |

# Ataque a ℓ-diversidad: datos auxiliares

## Segunda inferencia

| zip | edad | nacionalidad | enfermedad |
|---|---|---|---|
| 130** | <30 | * | Cardiopatía |
| 130** | <30 | * | Diabetes |
| 130** | <30 | * | Cáncer |
| 130** | <30 | * | Resfrío |
| 1485* | >40 | * | Cáncer |
| 1485* | >40 | * | Cardiopatía |
| 1485* | >40 | * | Resfrío |
| 1485* | >40 | * | Resfrío |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |
| 130** | 30-40 | * | Cáncer |

| nombre | zip | edad | nac. |
|---|---|---|---|
| Umeko | 13068 | 24 | Japonesa |

- Umeko no tiene cáncer.
- Umeko no tiene una enfermedad cardíaca.
- Umeko **no tiene diabetes**.

**Se aprende que Umeko tiene un resfrío**

# Limitaciones de ℓ-diversidad

## Ataques de asimetría y de similitud

### Asimetría

En la población, el 1 % tiene VIH. Un grupo con 50 % de casos de VIH y 50 % sin VIH es **2-diverso**.

Sin embargo, la **probabilidad** que el adversario asigna a cada integrante sube de:

**1 % → 50 %**

No se sabe quién tiene VIH, pero cada integrante es **50 veces** más sospechoso.

### Similitud

Este grupo es **3-diverso**:

| zip | edad | enfermedad |
|---|---|---|
| 476** | 2* | Gastritis |
| 476** | 2* | Úlcera gástrica |
| 476** | 2* | Cáncer gástrico |

…pero el adversario aprende que la persona tiene una **enfermedad estomacal**.

**ℓ-diversidad cuenta valores distintos, pero ignora su distribución y su significado**

# ¿Qué es *t*-closeness?

## Definición [Li, Li y Venkatasubramanian, 2007]

Una tabla *T* satisface ***t*-closeness** si, para cada grupo de filas con los mismos CId, la distancia entre la distribución del atributo sensible en el grupo y su distribución en toda la tabla es a lo más *t*.

$$D(P_{grupo}, P_{tabla}) \leq t$$

Para atributos categóricos se puede usar la **distancia de variación total**:

$$D(P, Q) = \tfrac{1}{2} \cdot \Sigma_i \, | p_i - q_i |$$

**Previene el ataque de asimetría**

**Con una distancia que considera el significado (Earth Mover's Distance) mitiga el de similitud**

**Costo: un t pequeño acerca todos los grupos a la tabla completa y reduce la utilidad**

# *t*-closeness: ejemplo

## Distancia de cada grupo a la tabla completa

Distribución de *enfermedad* en la tabla del ataque a ℓ-diversidad (12 filas):

| Grupo | Cardiopatía | Diabetes | Cáncer | Resfrío | D |
|---|---|---|---|---|---|
| **Tabla completa** | 2/12 | 1/12 | 6/12 | 3/12 | — |
| **130**, <30** | 1/4 | 1/4 | 1/4 | 1/4 | **0,25** |
| **1485*, >40** | 1/4 | 0 | 1/4 | 2/4 | **0,33** |
| **130**, 30-40** | 0 | 0 | 4/4 | 0 | **0,50** |

### Cálculo para el grupo <30 (en doceavos):

$$\tfrac{1}{2} \cdot ( |3-2| + |3-1| + |3-6| + |3-3| ) / 12 = 0{,}25$$

**La tabla satisface t-closeness solo para t ≥ 0,5**

**El grupo más alejado (30-40) es el homogéneo: el mismo que permitió el ataque de homogeneidad**

# Resumen

## *k*-anonimato, ℓ-diversidad y *t*-closeness

Enfoques **formales y sistemáticos** de de-identificación: una mejora sustantiva respecto de los enfoques ad hoc.

Siguen siendo **susceptibles a ataques**: la protección de la privacidad depende de la **información auxiliar** del adversario.

La automatización tiene un **alto costo computacional**: dada una tabla $T$, encontrar una tabla $T'$ que satisfaga $k$-anonimato y maximice la utilidad es un problema **NP-difícil** (Meyerson y Williams, 2004).

***t*-closeness** exige que la distribución del atributo sensible en cada grupo se aproxime a la de la tabla completa, lo que previene los ataques de asimetría y similitud.



Parte 6

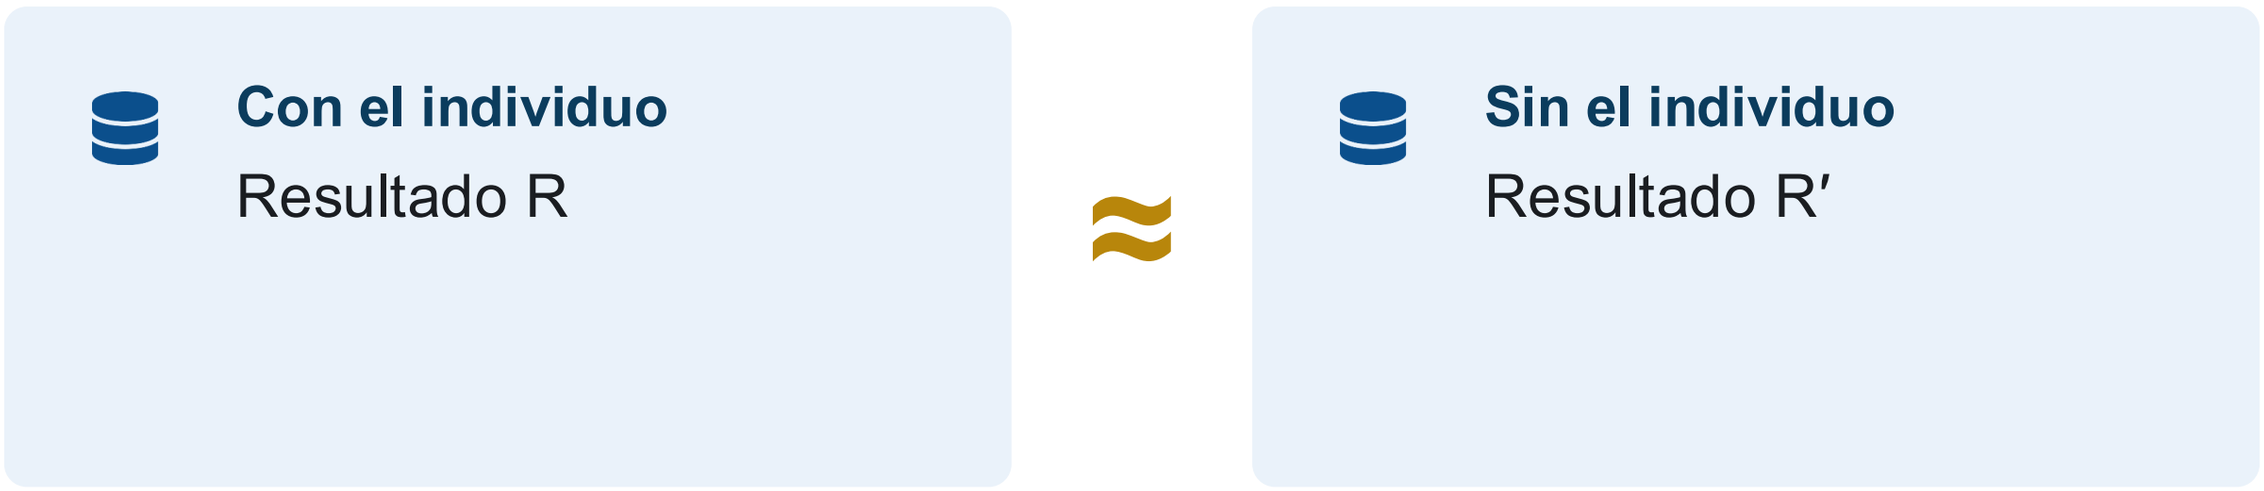
# Privacidad diferencial

# ¿Qué es privacidad diferencial?

## Idea general

La privacidad diferencial es un **mecanismo** que garantiza que un algoritmo aleatorio que opera sobre un conjunto de datos **no revele información específica** de ningún individuo.

Esto se logra asegurando que la probabilidad de obtener un resultado particular sea **casi la misma**, independientemente de si un individuo está o no incluido en el conjunto de datos.



# ¿Qué es privacidad diferencial?

## Definición formal

Formalmente, para dos entradas *x* e *y* que difieren en un solo individuo, y para todo conjunto de salidas posibles *S*, la probabilidad de que el algoritmo *f* produzca un resultado en *S* debe estar acotada por un factor $e^{\varepsilon}$, donde **ε** es un parámetro que controla el nivel de privacidad.

$$\Pr[\, f(x) \in S \,] \leq e^{\varepsilon} \cdot \Pr[\, f(y) \in S \,]$$

para todo $S \subseteq R$

**A continuación se analiza el mecanismo**

# ¿Qué es privacidad diferencial?

## Esquema de la definición

$f :$  $\rightarrow R$

**Algoritmo aleatorio**

**a distancia 1**

**x** ⟷ **y**

**Bases de datos idénticas, salvo por un individuo**

*f(x)* ⟷ *f(y)*

**casi iguales**

Se dice que *f* es **ε-diferencialmente privada** si:

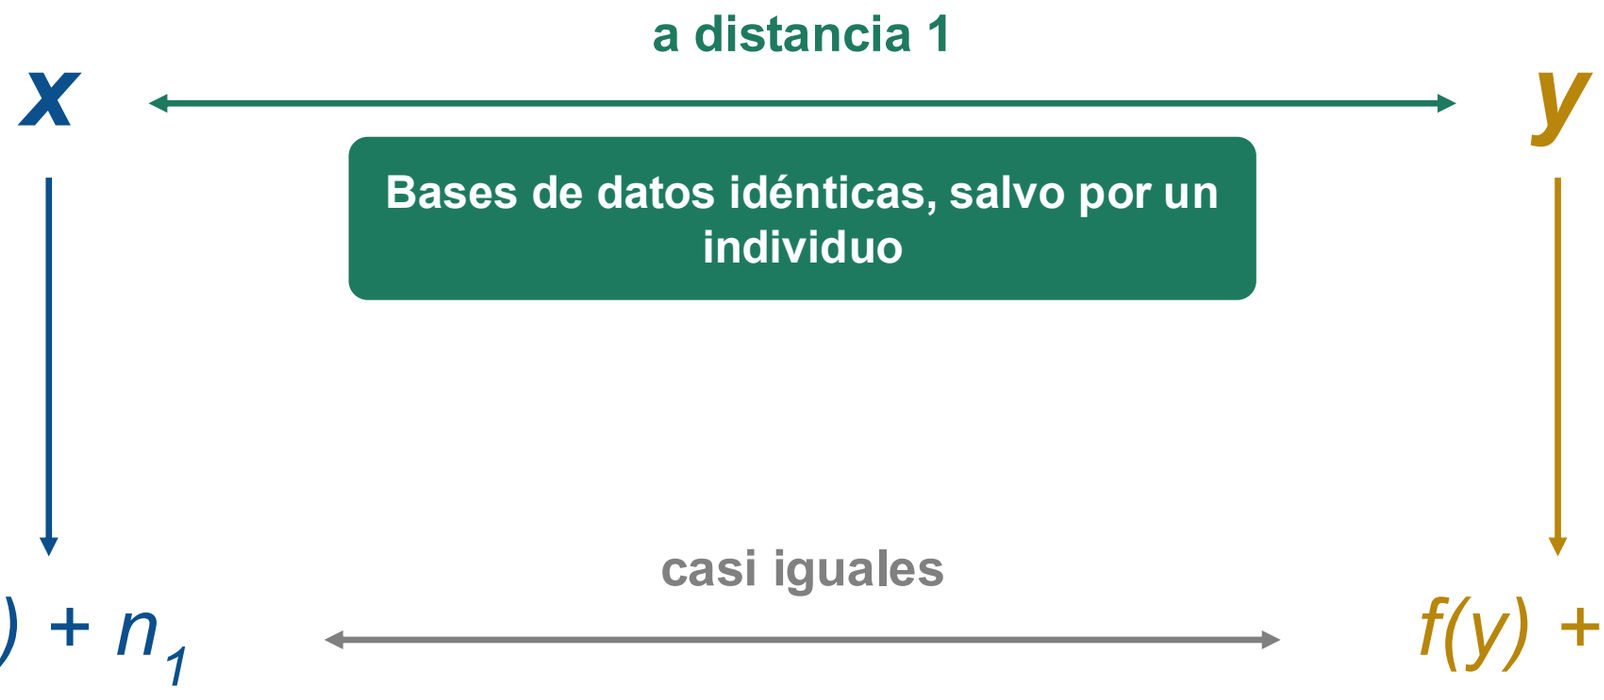
$$\Pr[\, f(x) \in S \,] \leq e^{\varepsilon} \cdot \Pr[\, f(y) \in S \,], \quad S \subseteq R$$

# ¿Qué es privacidad diferencial?

## Mecanismo: agregar ruido

$f:$  $\rightarrow R$

**Algoritmo aleatorio**




**Los mecanismos de PD agregan ruido aleatorio a los resultados**

El **ruido** es la perturbación añadida a los datos para proteger la información. Su magnitud depende de la **sensibilidad** de la consulta.

# Privacidad diferencial: ejemplo

## Sensibilidad de una consulta

¿Cuántas personas del conjunto de datos tienen **40 años o más**?

```
SELECT COUNT(*) FROM person WHERE age >= 40;
```

**14237**

### ¿Cuál es la sensibilidad de esta consulta?

Es decir, ¿cuánto puede variar, **como máximo**, el resultado si se agrega o se quita un individuo?

**Respuesta**

**1**

# Privacidad diferencial: ejemplo

## Mecanismo de Laplace

```
SELECT COUNT(*) FROM person WHERE age >= 40;
```

**f(x) = 14237**

$$F(x) = f(x) + Lap( s / \varepsilon )$$

**s** = sensibilidad = 1

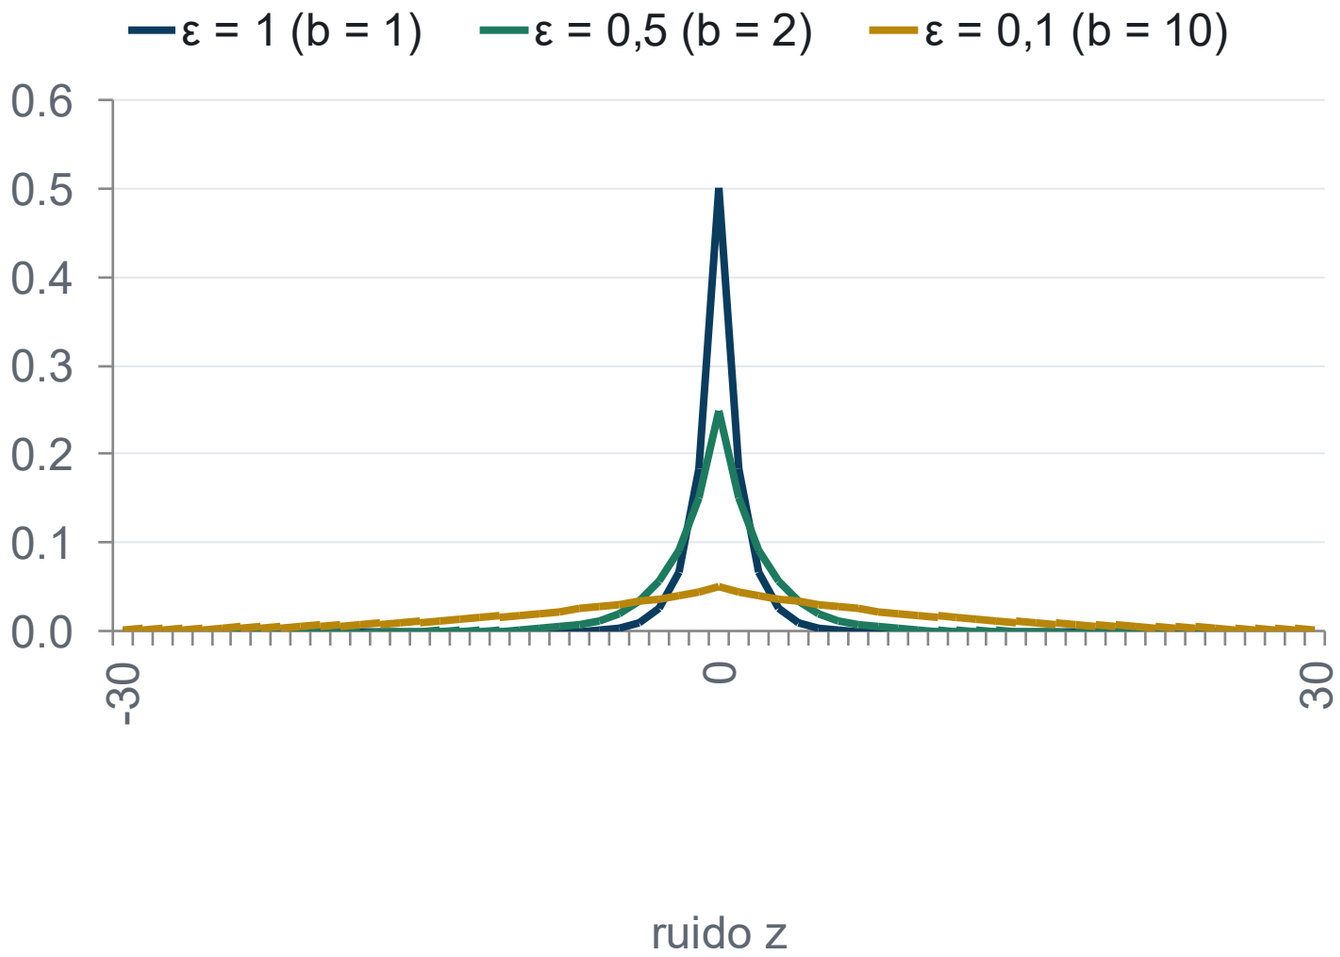
**ε** = presupuesto de privacidad = 0,1

## Cuatro ejecuciones del mecanismo:

| *F(x)* | *F(x)* | *F(x)* | *F(x)* |
|---|---|---|---|
| **14211,230613** | **14265,917434** | **14265,770017** | **14209,093826** |

# La distribución de Laplace

## Forma y escala del ruido




$$p(z) = e^{-|z|/b} / 2b$$
$$b = s / \varepsilon$$

- Media 0: el ruido no sesga la respuesta.
- Desviación estándar: $\sqrt{2} \cdot b$.
- **ε menor ⇒ b mayor ⇒** más ruido y más privacidad.

**En el ejemplo: s = 1 y ε = 0,1 ⇒ b = 10. La respuesta 14237 se desvía típicamente en ± 14, poco relevante para un conteo de ese tamaño**

# ¿Cuánto ruido es suficiente?

## Consulta maliciosa

```
SELECT COUNT(*) FROM person
WHERE name = 'Alan Brito'
  AND target = '<=50K';
```

1

Consulta maliciosa

**+ ruido ⇒ F(x) =**

| | | |
|---|---|---|
| 18,475044 | −2,115105 | 13,167499 |
| −0,203654 | −0,688716 | 15,158466 |

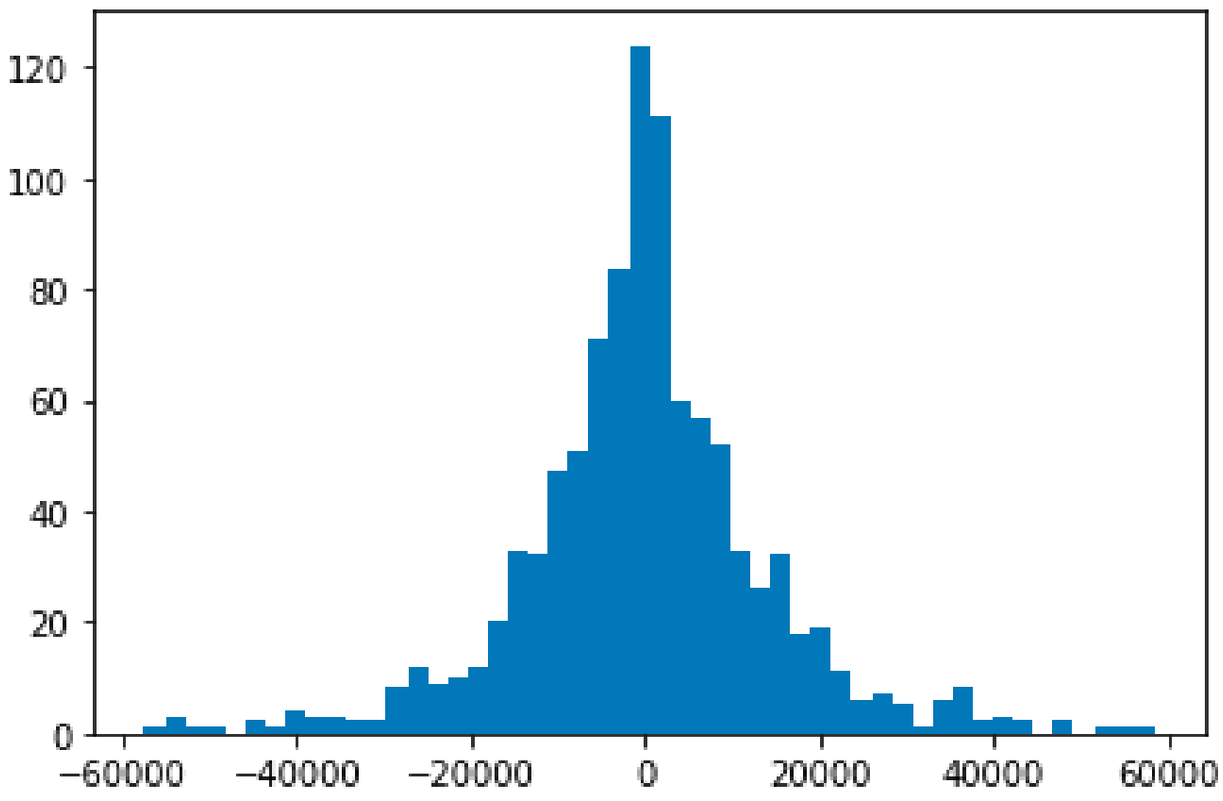
**¿Es realmente útil la respuesta?**

**No; pero no importa, porque la consulta era maliciosa (muy selectiva)**

# Repetición de una consulta

## ¿Qué ocurre si se repite muchas veces?

```
SELECT COUNT(*) FROM person
WHERE name = 'Alan Brito' AND target = '<=50K';
```




**Se puede deducir que el valor real es 1**

Por esta razón, ε se denomina **presupuesto**.

Las consultas **no son independientes**: el presupuesto debe distribuirse entre todas ellas, lo que produce resultados más ruidosos.

# Repetición de una consulta

## División del presupuesto

```
SELECT COUNT(*) FROM person
WHERE name = 'Alan Brito' AND target = '<=50K';
```

× 4

```
f(x) + Lap( 1 / (ε/4) )
```

**Si la consulta se ejecuta 4 veces, ε se divide en 4**

**El ruido de cada consulta será mayor**

# Composición secuencial

## Propiedad

- Si $F_1(x)$ satisface $\varepsilon_1$-privacidad diferencial, y
- si $F_2(x)$ satisface $\varepsilon_2$-privacidad diferencial,

entonces el mecanismo $G(x) = (F_1(x), F_2(x))$, que publica ambos resultados, satisface **$(\varepsilon_1 + \varepsilon_2)$-privacidad diferencial**.

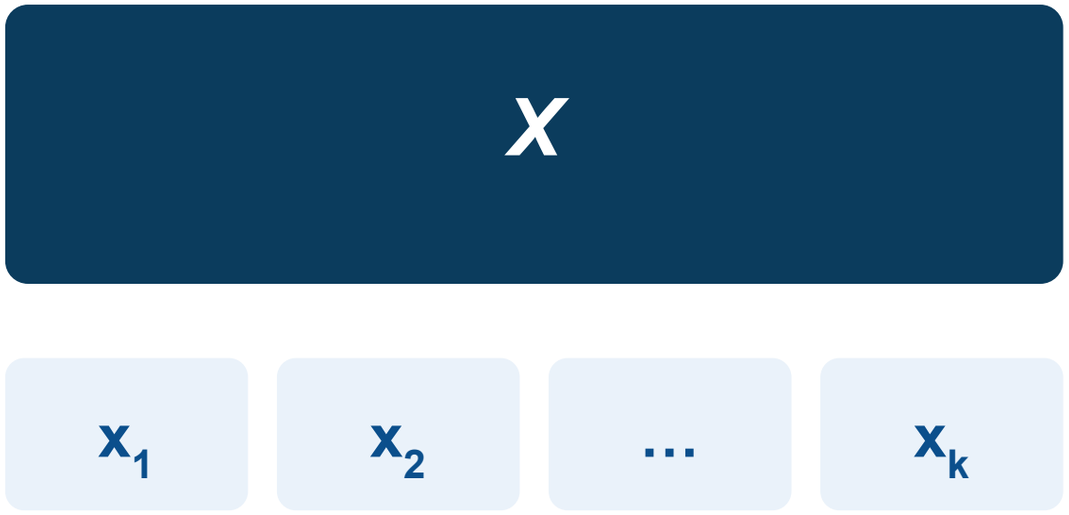


# Composición paralela

## Propiedad

Si $F(x)$ satisface ε-privacidad diferencial y el conjunto de datos $X$ se divide en $k$ partes disjuntas tales que $x_1 \cup \ldots \cup x_k = X$,

entonces el mecanismo que publica $F(x_1)$, …, $F(x_k)$ satisface **ε-privacidad diferencial**.




**Esta cota es mucho mejor que la que entrega la composición secuencial: kε-privacidad diferencial**

# Composición paralela

## Ejemplo: nivel educacional por sexo

### Conteos exactos

| Educación | Mujer | Hombre |
|---|---|---|
| **10th** | 295 | 638 |
| **11th** | 432 | 743 |
| **12th** | 144 | 289 |
| **1st-4th** | 46 | 122 |
| **5th-6th** | 84 | 249 |
| **7th-8th** | 160 | 486 |
| **9th** | 144 | 370 |
| **Assoc-acdm** | 421 | 646 |
| **Assoc-voc** | 500 | 882 |
| **Bachelors** | 1619 | 3736 |
| **Doctorate** | 86 | 327 |
| **HS-grad** | 3390 | 7111 |
| **Masters** | 536 | 1187 |
| **Preschool** | 16 | 35 |
| **Prof-school** | 92 | 484 |
| **Some-college** | 2806 | 4485 |

### Conteos con ruido (celdas disjuntas)

| Educación | Mujer | Hombre |
|---|---|---|
| **10th** | 295,591316 | 638,730833 |
| **11th** | 433,991320 | 742,901816 |
| **12th** | 144,546311 | 289,543775 |
| **1st-4th** | 45,877242 | 123,385749 |
| **5th-6th** | 86,657895 | 249,939610 |
| **7th-8th** | 161,499974 | 485,533936 |
| **9th** | 143,441692 | 367,792887 |
| **Assoc-acdm** | 420,879967 | 644,833957 |
| **Assoc-voc** | 500,347331 | 881,176781 |
| **Bachelors** | 1618,321878 | 3736,108821 |
| **Doctorate** | 83,983045 | 325,787201 |
| **HS-grad** | 3390,710973 | 7112,123852 |
| **Masters** | 537,215908 | 1185,515231 |
| **Preschool** | 15,782764 | 32,575344 |
| **Prof-school** | 90,655808 | 483,799082 |
| **Some-college** | 2804,440558 | 4485,117936 |

# Sensibilidad de SUM

## Recorte de valores (clipping)

Al agregar o quitar una persona, SUM(age) cambia en **su edad**: la sensibilidad es la mayor edad posible, que en principio no está acotada. Solución: recortar los valores a un rango [0, *U*].

```
SELECT SUM(LEAST(GREATEST(age, 0), 100))
FROM person;
```

**s = 100**

| Consulta | Sensibilidad s |
|---|---|
| COUNT(*) | 1 |
| SUM con valores en [0, U] | U |
| AVG | vía SUM y COUNT |

**Compromiso: un U muy bajo introduce sesgo; uno muy alto, mucho ruido**

**Ataque de diferenciación revisitado: con ε = 1 repartido entre las dos consultas, cada SUM recibe Lap(200). La diferencia de 39 años queda oculta bajo un ruido del orden de ± 400**

# Sensibilidad de AVG

## Combinación de SUM y COUNT

AVG no se perturba directamente: se calcula a partir de una suma y un conteo con ruido, **dividiendo el presupuesto** entre ambos (composición secuencial).

```
suma   = SUM(edad recortada) + Lap(100 / (ε/2))
conteo = COUNT(*)            + Lap(  1 / (ε/2))
AVG    ≈ suma / conteo
```

**Con ε = 1, suponiendo SUM(age) = 1256257 y n = 32561 (dataset Adult):**

### Grupo grande (n = 32561)

AVG ≈ 38,58 ± 0,01 años: el ruido es despreciable.

### Grupo pequeño (n = 5)

El mismo ruido produce errores de decenas de años: la respuesta no sirve.

# Garantías de la privacidad diferencial

## Indistinguibilidad

El resultado del mecanismo **no permite** a un adversario distinguir entre las dos bases de datos.

El resultado es el mismo, **participe o no** un individuo.

Coincide con una buena intuición de privacidad: «nada malo me ocurre como resultado de mi participación en el análisis»; y si algo malo ocurre, habría ocurrido aun sin mi participación.

Las **definiciones formales** permiten demostrar que un mecanismo satisface privacidad diferencial.

# Garantías de la privacidad diferencial

## Independencia de los datos auxiliares

¡La garantía se mantiene **independientemente de los datos auxiliares** que pudiera tener un adversario!

Incluso en el caso en que el adversario conoce toda la base de datos, **excepto la fila objetivo**.

Previene los ataques de asociación que afectan a *k*-anonimato y a ℓ-diversidad.

Es la única forma conocida que se aproxima a una «**anonimización verdadera**».

# Limitaciones de la privacidad diferencial

## Desventajas

### Solo sirve para respuesta a consultas, no para datos sintéticos

- Es una propiedad de un **mecanismo**, no de los datos.
- En muchos casos, el mecanismo puede generar datos sintéticos «suficientemente buenos».

### Garantía difícil de interpretar

- Está parametrizada por ε. ¿Qué valor de ε es suficiente?
- **ε muy pequeño:** poca utilidad.
- **ε muy grande:** la re-identificación vuelve a ser posible.
- Aún no se conoce la respuesta.



## Cierre

# Resumen

# Resumen (parte 1)

## De-identificación y *k*-anonimato

### De-identificación / anonimización

- Elimina los identificadores exclusivos para reducir el riesgo de re-identificación.
- Los enfoques ad hoc conllevan un alto riesgo de errores.
- Es la técnica más utilizada.
- La seudonimización **no** es anonimización: los datos siguen siendo personales.

### *k*-Anonimato

- Formaliza la de-identificación sistemática.
- Requiere grupos de tamaño al menos *k*.
- Es susceptible a ataques de homogeneidad y de datos auxiliares.

# Resumen (parte 2)

## ℓ-Diversidad y privacidad diferencial

### ℓ-Diversidad

- Requiere grupos **diversos**.
- Previene ataques de homogeneidad.
- Previene ataques de datos auxiliares cuando el adversario conoce menos de $\ell - 2$ datos negativos acerca del grupo.
- *t*-closeness la extiende considerando la distribución de los valores.

### Privacidad diferencial

- Propiedad formal de un **mecanismo** (algoritmo o análisis).
- Corresponde a la noción de indistinguibilidad: **mismo resultado**, participe o no el individuo.
- La garantía es **independiente de los datos auxiliares** del adversario.






# Fin de la clase